

使用卷積神經網路進行眼底影像黃斑部病 變分類之研究

A Study on Macular Degeneration Classification Using
Convolutional Neural Networks

112316108 林知涵

課程名稱：深度學習

指導老師：林紋正

目錄 (Table of Contents)

1. 任務說明
2. 資料說明
3. 探索性資料分析
4. 資料前處理
5. 實驗設計
6. 實驗結果與分析
7. 結論與討論
8. 參考文獻
9. 附錄

一、任務說明 (Task Description)

1.1 問題背景與研究動機

黃斑部病變 (Macular Degeneration) 是一種常見的眼部疾病，若未及早診斷與治療，可能導致視力嚴重受損。隨著醫學影像資料量快速成長，如何透過深度學習模型自動分析眼底影像，輔助醫師進行疾病分類與判斷，成為近年醫療人工智慧的重要研究方向。

本研究使用公開之眼底影像資料集，嘗試利用卷積神經網路 (Convolutional Neural Networks, CNN) 建立自動化影像分類模型，評估不同模型架構在眼底影像疾病分類任務中的效能與可行性。

1.2 任務目標

本研究之主要目標如下：

- 建立一套以 CNN 為基礎之眼底影像分類系統
- 比較不同 CNN 模型架構於分類任務中的表現
- 分析資料增強與遷移學習對模型效能之影響

1.3 預期成果

- 提供不同 CNN 模型於驗證集上的分類準確率比較
- 分析模型是否出現 overfitting 或 underfitting
- 評估深度學習模型於醫療影像分類應用上的潛力

二、資料說明 (Data Description)

2.1 資料來源

本研究使用 Kaggle 公開資料集：

Macular Degeneration Disease Dataset

<https://www.kaggle.com/datasets/orvile/macular-degeneration-disease-dataset>

2.2 資料內容與類別

資料集為眼底彩色影像，依疾病類型分為四類：

類別名稱	說明
AMD	黃斑部病變
Cataract	白內障
Diabetes	糖尿病視網膜病變
Normal	正常眼底

2.3 資料分佈

類別	Training	Validation
AMD	394	100
Cataract	400	100
Diabetes	400	100
Normal	400	100

資料集已切分為訓練集 (Training Set) 與驗證集 (Validation Set)，整體類別分佈大致平衡。

三、探索性資料分析 (Exploratory Data Analysis, EDA)

3.1 影像觀察

透過隨機抽樣影像觀察，不同疾病類型在顏色分佈與病灶位置上具有差異，但整體特徵仍具高度複雜性，需透過 CNN 自動萃取特徵進行判斷。

3.2 類別分佈分析

各類別樣本數量相近，因此本研究未額外使用過採樣或欠採樣方法。

四、資料前處理(Data Preprocessing)

4.1 影像前處理流程

本研究使用 PyTorch 進行影像前處理，流程如下：

- 將影像統一調整為 224×224
- 將影像轉換為 Tensor 格式
- 使用 ImageNet 統計值進行像素正規化
- 使用 `ImageFolder` 依資料夾結構自動標註類別

4.2 資料增強(Data Augmentation)

訓練階段使用以下資料增強方式以提升模型泛化能力：

- Random Horizontal Flip
- Random Rotation

驗證集僅進行 Resize 與 Normalize，以確保評估結果之公平性。

五、實驗設計(Experimental Design)

為確保實驗結果具有可比較性與可重現性，本研究於所有實驗中 統一程式碼規範、資料前處理方式與訓練超參數設定，僅針對研究目標調整單一變因進行比較分析。

5.1 整體實驗與程式碼規範(Experimental Protocol)

本研究所有實驗皆遵循以下統一規範：

- 硬體與運算環境
 - 使用 PyTorch 深度學習框架

- 程式自動偵測 CUDA(`torch.cuda.is_available()`), 若可用則使用 GPU 訓練
- 記錄每次實驗之 Training Time(秒)

2. 實驗可重現性

- 固定 random seed(`torch`、`numpy`、`random`), 確保實驗結果可重現

3. 影像輸入設定

- 預設輸入影像尺寸為 **224 × 224**
- 提供可切換之輸入尺寸設定(128 / 224 / 256)

5.2 資料處理與訓練固定設定 (Controlled Variables)

為避免非必要變因影響實驗結果, 下列設定於所有實驗中皆保持一致:

(一) 資料處理方式

- 使用 `torchvision.datasets.ImageFolder` 讀取訓練集(train)與驗證集(valid)
 - 僅訓練集使用資料增強(Data Augmentation)
 - RandomHorizontalFlip
 - RandomRotation
 - 驗證集不使用任何 augmentation
 - 所有影像 resize 為指定輸入尺寸後再進行 normalization
-

(二) 固定訓練超參數

項目	設定
Loss Function	CrossEntropyLoss
Optimizer	Adam
Epochs	50
Batch Size	128
Normalization	ImageNet mean/std

5.3 實驗設計一：不同 CNN 模型架構比較 (Experiment 1)

實驗目的

比較不同卷積神經網路模型於相同資料與訓練條件下的分類效能，建立模型效能基準。

實驗設定

- 固定輸入影像尺寸：**224 × 224**
- 固定訓練超參數與資料處理流程

比較模型

1. SimpleCNN (Baseline)

階段 (Stage)	操作內容 (Detailed Operations)	輸出通道 (Channels)	空間尺寸 (Resolution)
Input	原始眼底影像影像輸入	3	224*224
Layer 1	3*3 Conv, BatchNorm, ReLU, 2*2 MaxPool	32	112*112

Layer 2	3*3 Conv, BatchNorm , ReLU, 2*2 MaxPool	64	56*56
Layer 3	3*3 Conv, BatchNorm , ReLU, 2*2 MaxPool	128	28*28
Neck	Adaptive Global Avg Pool (GAP)	128	1*1
FC 1	Flatten + Fully Connected (128 units) + ReLU	-	128 (Vector)
Regularize	Dropout (p=0.3)	-	128 (Vector)
Output	Linear Classifier (num_classes=4)	-	4

2. ResNet18 (Pretrained)

- 該模型以四個殘差階段 (Stage) 為核心，利用 3×3 的 BasicBlock 進行特徵提取，並在每個階段切換時將空間解析度減半、通道數翻倍，最終透過全域平均池化 (GAP) 整合 512 個特徵通道進行分類。

3. MobileNetV2 (Pretrained)

- 該模型採用了一系列倒殘差瓶頸層 (Bottleneck)，透過擴張係數 t 控制特徵在模組內部的維度變化。值得注意的是，該模型在分類器前使用了一層 1×1 卷積將特徵維度擴展至 1280，以強化高階特徵的表達能力，隨後才進行池化與分類。」

5.4 實驗設計二：不同輸入影像尺寸比較 (Experiment 2)

實驗目的

分析輸入影像尺寸對模型分類效能之影響。

實驗設定

- 固定模型 **resnet18**
- 固定訓練流程與超參數

比較條件

- `img_size = 128`
- `img_size = 224`
- `img_size = 256`

透過比較不同解析度下的準確率與訓練時間，評估影像細節對模型效能的影響。

5.5 實驗三：Freeze vs Fine-tune (Bonus Experiment A)

實驗目的

比較遷移學習中 凍結特徵萃取層 (**Freeze**) 與 全模型微調 (**Fine-tune**) 的效能差異。

實驗設定

- 模型：**Resnet18**
- 輸入尺寸： 224×224

比較方式

1. Freeze Backbone

- 凍結 backbone 參數
- 僅訓練最後全連接層 (fc)

2. Fine-tune

- 解凍全部模型參數

- 進行端到端訓練
-

5.6 實驗四：資料增強影響分析 (Bonus Experiment B)

實驗目的

分析資料增強 (Data Augmentation) 對模型泛化能力之影響。

實驗設定

- 模型 : Resnet18
- 輸入尺寸 : 224×224

比較條件

1. 無資料增強
 - 僅 Resize(224×224) + Normalize
 2. 有資料增強
 - 隨機左右翻轉
 - 隨機旋轉15度
-

六、實驗結果與分析 (Results and Analysis)

本章節依照前述實驗設計，分別呈現 實驗一、實驗二、實驗三、實驗四 之實驗結果，並針對模型效能進行比較與分析。


所有圖表皆以驗證集 (Validation Set) 結果為主要分析依據。

6.1 實驗一：不同 CNN 模型架構比較 (img_size = 224)


6.1.1 訓練過程分析 (Loss / Accuracy Curve)

- **Simple CNN**


- **Figure 6.1 : Training / Validation Loss Curve**




實驗一-2 不同模型比較 | resnet18 Loss Curve





實驗一-3 不同模型比較 | mobilenetv2 Loss Curve



- **Figure 6.2: Training / Validation Accuracy Curve**





模型效能表現 (Performance Comparison)


1. 實驗一：不同 CNN 模型架構比較

本實驗旨在建立效能基準，觀察 SimpleCNN、ResNet18 與 MobileNetV2 的學習特徵。

- **SimpleCNN (Baseline):** 出現欠擬合 (Underfitting)。其 Loss 曲線雖平穩下降，但收斂速度緩慢，且驗證準確率穩定後僅維持在約 70%。這反映出淺層網路的特徵萃取能力不足，無法捕捉眼底影像中複雜的病灶資訊。
- **ResNet18:** 學習能力強但存在震盪。Accuracy 快速攀升至 95% 以上，展現了殘差結構對深層網路訓練的優勢。然而，其 Loss 曲線在訓練初期與中期出現較劇烈的跳動 (Spikes)，顯示模型在優化過程中穩定性較差，可能需要更精細的學習率排程調整。
- **MobileNetV2:** 收斂最快但有過擬合風險。其 Accuracy 曲線在極短的 Epoch 內即趨於穩定，效能與 ResNet18 相當。但觀察 Loss 曲線發現，訓練後期 Training Loss 持續下降，而 Validation Loss 卻微幅上升並開始震盪，這是輕微過擬合 (Overfitting) 的徵兆，建議配合早停法使用。

exp_Name	img_size	Acc	precision_macro	recall_macro	f1_macro	epoch
實驗一 mobilenetv2	224	0.940	0.940	0.940	0.939	19
實驗一 resnet18	224	0.950	0.950	0.950	0.950	17
實驗一 simplecnn	224	0.725	0.724	0.725	0.721	50


■ **Figure 6.5: MobileNetV2 Confusion Matrix**




6.2 實驗二：不同輸入影像尺寸比較(Resnet18)


6.2.1 訓練曲線比較(Loss / Accuracy)


- **Figure 6.6:** 不同 img_size 的 Loss Curve(可疊圖)






- **Figure 6.7:** 不同 img_size 的 Accuracy Curve





6.2.2 實驗二結論：不同輸入尺寸對 ResNet18 模型效能之影響

exp_Name	img_size	Acc	precision_macro	recall_macro	f1_macro	epoch
實驗二 resnet18	128	0.898	0.904	0.898	0.894	13
實驗二 resnet18	256	0.940	0.941	0.940	0.940	14
實驗二 resnet18	224	0.950	0.950	0.950	0.950	17





本實驗分析影像解析度對 ResNet18 模型穩定性的影響。

- 低解析度 (**128 × 128**): 曲線劇烈震盪且不穩定。當尺寸較小時, Validation Loss 呈現明顯且頻繁的波動 (Fluctuation)。這說明影像縮小導致關鍵病灶特徵丟失, 使模型對驗證數據的預測信心起伏較大, 泛化能力最差。
- 中高解析度 (**224/256**): 收斂過程趨於平滑。隨著尺寸增加, Loss 曲線的震盪顯著改善, 且 Validation Accuracy 能穩定維持在 96%~98%。這證明較大的輸入解析度能提供充足的特徵資訊供模型學習, 且在 224 與 256 之間, 效能已趨於飽和, 兩者表現接近。

6.3 實驗三: Freeze vs Fine-tune (ResNet18)


6.3.1 訓練行為比較

- **Figure 6.8:** Freeze vs Fine-tune Loss Curve




- **Figure 6.9:** Freeze vs Fine-tune Accuracy Curve

實驗3-1 Freeze backbone (只訓練 fc) | resnet18 Accuracy Curve



實驗3-2 No Freeze|resnet18 Accuracy Curve



6.3.2 實驗三結論

exp_Name	img_size	Acc	precision_macro	recall_macro	f1_macro	epoch
實驗三 resnet18 (Fine-tune)	224	0.950	0.950	0.950	0.950	17
實驗三 resnet18 (Freeze backbone)	224	0.8025	0.799	0.802	0.799	50

本實驗探討遷移學習策略在 ResNet18 上的效能權衡。[Image comparing freeze backbone vs fine-tuning accuracy curves]


- 凍結骨幹 (Freeze Backbone): 高穩定性但有效能瓶頸。其 Loss 與 Accuracy 曲線呈現極為平滑且穩定的走勢，幾乎沒有震盪。雖然模型能快速收斂，但 Validation Accuracy 最終卡在約 80%-93% 的區間，出現了「效能天花板」，因為固定的預訓練參數無法完全適應眼底影像的特殊分佈。
- 全模型微調 (Fine-tune): 高效能但高波動性。Fine-tune 策略讓 Accuracy 突破瓶頸，達到 96%-98% 的高水準。然而，其 Loss 曲線在訓練中後期出現鋸齒狀大幅跳動，反映出全模型訓練對學習率極其敏感，雖然能獲得更佳的特徵表達，但優化過程較不穩定。

6.4 實驗四：有 / 無 Data Augmentation(ResNet18)


6.4.1 訓練穩定性分析

- Figure 6.12: No Augmentation Loss / Accuracy



實驗4-1 沒有 agumentation |simplecnn Loss Curve



實驗4-2 有 augmentation (Flip + Rotation) | simplecnn Loss Curve




實驗4-3 沒有 augmentation | resnet18 Loss Curve




- **Figure 6.13:** With Augmentation Loss / Accuracy


實驗4-1 沒有 augmentation | simplecnn Accuracy Curve




實驗4-2 有 augmentation (Flip + Rotation) | simplecnn Accuracy Curve



實驗4-3 沒有 augmentation | resnet18 Accuracy Curve



實驗4-4 有 augmentation (Flip + Rotation) | resnet18 Accuracy Curve



6.4.2 實驗四結論:

exp_Name	img_size	Acc	precision_macro	recall_macro	f1_macro	epoch
實驗4-2 有 augmentation (Flip + Rotation)	224	0.963	0.963	0.963	0.962	21
實驗4-1 無 augmentation	224	0.950	0.950	0.950	0.950	0.950

本實驗以 MobileNetV2 觀察資料增強如何抑制過擬合。[Image showing training vs validation gap with and without data augmentation]

- 無資料增強：嚴重的過擬合 (Overfitting)。觀察 Accuracy 曲線，Training 與 Validation 之間存在顯著的「泛化鴻溝」：訓練集準確率迅速接近 100%，但驗證集始終落後一段距離。Loss 曲線更顯示 Training Loss 趨近於 0，但 Validation Loss 卻在 0.15 以上震盪且無法下降，模型陷入了「死記」樣本的困境。
- 有資料增強：提升泛化能力與魯棒性。引入翻轉與旋轉後，雖然訓練初期的 Loss 下降速度變慢（因為數據變異增加，學習難度提高），但 Training 與 Validation 的兩條曲線貼合度大幅提升。這證明資料增強迫使模型學習更具強健性的結構特徵，而非特定的像素排列，從而縮小了驗證誤差。

6.5 結果總結與討論 (Overall Discussion)

最好的模型

exp_Name	img_size	Acc	precision_macro	recall_macro	f1_macro	epoch
resnet18	224	0.950	0.950	0.950	0.950	17
實驗二 resnet18	224	0.950	0.950	0.950	0.950	17
實驗三 resnet18 (Fine-tune)	224	0.950	0.950	0.950	0.950	17
實驗4-2 有 augmentation (Flip + Rotation)	224	0.963	0.963	0.963	0.962	21

1. 最佳模型架構與訓練策略 實驗結果顯示，ResNet18 能達到 96%的高準確率，遠優於基礎 CNN 模型。考量到醫療場景的實際應用需求（如行動裝置部署），MobileNetV2

在維持高準確率的同時具備輕量化優勢，是極具潛力的選擇。最佳的訓練策略為採用遷移學習的 **Fine-tune** (全模型微調) 搭配 **224 × 224** 以上的輸入尺寸，這能確保模型突破效能瓶頸並獲得足夠的特徵細節。

2. 準確率與穩定性的權衡 (Trade-off) 我們發現「高效能」往往伴隨著「低穩定性」。例如 Fine-tune 策略雖然能達到最高準確率，但其 Loss 曲線震盪幅度遠大於 Freeze Backbone。這提示在追求 State-of-the-Art (SOTA) 效能時，需更精細地調整學習率 (Learning Rate) 或使用排程器 (Scheduler) 來換取訓練過程的穩定。

3. 泛化能力的重要性 在醫療影像數據量有限的情況下，資料增強 (**Data Augmentation**) 被證實是不可或缺的環節。雖然它未大幅改變最終的最高準確率數值，但卻顯著縮小了 Training 與 Validation Loss 之間的差距，成功抑制了過擬合 (Overfitting) 現象。這證明了經過幾何變換增強的模型，其學到的特徵更具魯棒性 (Robustness)，更能應對臨床上真實多變的影像數據。

總結來說，建立一個可靠的眼底影像輔助診斷系統，建議優先採用「預訓練輕量化模型 (如 **MobileNetV2**) + 全模型微調 (**Fine-tune**) + 資料增強 (**Augmentation**)」之組合，以在效能、運算成本與泛化能力間取得最佳平衡。